

# Cinema Analytics

Suporte a Decisão Financeira na Indústria Cinematográfica (2006–2026)

Disciplina: Introdução a Análise de Dados | Grupo 10

## 1 Contextualização

A indústria cinematográfica envolve investimentos de alto risco: orçamentos que ultrapassam centenas de milhões de dólares e retorno comercial incerto. Este projeto analisa **2.501 filmes** lançados entre 2006 e 2026, com dados do TMDb, para apoiar decisões de investimento e produção. O dashboard consolida indicadores financeiros ajustados por inflação — ROI, lucro e receita reais — e de aceitação pública (notas do público), permitindo identificar padrões entre gênero, orçamento, duração e desempenho. A solução atende dois perfis: (i) **investidores e produtores**, que buscam mitigar risco e otimizar a alocação de orçamento por gênero; e (ii) **analistas de mercado**, que investigam a relação entre duração, avaliação crítica e bilheteria. Ao transformar dados brutos em métricas comparáveis no tempo, a aplicação viabiliza decisões baseadas em evidências sobre quais combinações de fatores maximizam o retorno.

## 2 Perguntas de Negócio – Indicadores

- Orçamento × Retorno:** como o orçamento influencia a receita e o lucro proporcional (ROI)?  
*Indicadores:* orçamento real, receita real, ROI real (tendência OLS).
- Gênero × Desempenho:** qual a relação entre gênero e retorno financeiro médio ao longo do tempo?  
*Indicadores:* ROI, lucro, receita e nota média por gênero.
- Avaliação × Lucro:** filmes melhor avaliados pelo público geram maior lucro?  
*Indicadores:* nota média × lucro real (correlação OLS).
- Duração × Sucesso:** qual o impacto da duração no ROI e na recepção do público?  
*Indicadores:* tempo de duração × ROI e nota.
- Combinações ótimas:** quais combinações de gênero e faixa de orçamento maximizam o ROI?  
*Indicadores:* ROI médio por célula (heatmap gênero × orçamento).

**KPIs monitorados:**

| KPI                      | Definição                                     | Meta    |
|--------------------------|-----------------------------------------------|---------|
| ROI Real Médio           | Média do ROI real ( $\times 100$ )            | > 20%   |
| Taxa de Assertividade    | % de filmes com receita real > orçamento real | > 60%   |
| Receita Real Média/Filme | Média da receita real (em milhões de USD)     | > \$50M |

## 3 Pipeline de Dados

O pipeline segue a arquitetura em camadas *medallion* (Bronze  $\rightarrow$  Trusted) e integra **duas fontes externas**, conforme a Figura 1.

**Aquisição dos dados.** A descoberta de filmes usa a API do TMDb (`/discover/movie`) fatiada **por ano** — estratégia que contorna o teto de 10 mil resultados por consulta — com filtro de relevância (`vote_count  $\geq$  1000`). Cada título é enriquecido via `/movie/{id}` (orçamento, receita, gênero, nota), totalizando **3.071 filmes**. O índice de inflação CPI-U é adquirido da API pública do *Bureau of Labor Statistics* (BLS), série CUUR0000SA0; a média anual é calculada a partir dos 12 valores mensais, com *fallback* estático para anos ainda não publicados.




Figura 1 – Fluxo do pipeline: TMDB alimenta a Bronze; o BLS (CPI-U) é integrado no ETL para o ajuste inflacionário.

**Limpeza e tratamento.** Deduplicação por `tmdb_id` (aplicada na extração e revalidada no ETL); remoção de registros nulos em campos essenciais; e **validação contratual** por meio de *schemas pandera* nas duas camadas (modo *lazy*, que acumula todas as violações antes de falhar). O filtro de integridade financeira ( $budget > 0$  e  $revenue > 0$ ) reduz a base aos **2.501 filmes** aptos ao cálculo de ROI e lucro.

**Transformações.** Extração do ano de lançamento a partir da data de estreia; **junção** com a tabela de CPI por ano; e **deflação monetária** via  $fator = CPI_{base} / CPI_{ano}$  (base = último ano do intervalo), convertendo os valores nominais em valores reais comparáveis entre anos distintos. Em seguida são derivados o lucro real ( $receita - orcamento$ ), o ROI real ( $lucro/orcamento$ ) e o indicador booleano de assertividade ( $receita > orcamento$ ).

**Armazenamento.** A **camada Bronze** grava os dados brutos em CSV (`dados/brutos/`); a **camada Trusted** grava a base analítica enriquecida e validada em CSV (`dados/processados/`), consumida em modo somente leitura pelo dashboard.